以蛻變測試與突變分析檢驗語音助理的自然語言意圖路由

Oct 9, 2026 · @Rich

摘要

語音助理把一句話送到「開程式、播音樂、控制家電或交給模型」的意圖路由元件，輸入是自然語言，沒有標準答案可以比對；本研究以蛻變測試產生測試、以突變分析評估測試，對自製語音助理 J.A.R.V.I.S. 的本機路由（`router.py`，約 60 條正規表達式規則）做完整一輪「生成、評估、縮減、排序、回饋修正」。

方法上定義五條蛻變關係（同義改寫、語助詞、換語序、無關前綴、近似句），分別用模板規則與 Gemini 模型（溫度 0、0.3、0.7、1.0）生成改寫句，並自寫七種針對正規表達式的突變運算子，產生 927 個突變體，建立 3,355 條測試 × 927 個突變體的矩陣。

主要結果：第一次蛻變測試在 928 句裡找到 433 個違反，全是手寫測試沒抓到的；五輪回饋修正後，規則式批次的違反從 706 降到 7、模型批次從約 415 降到約 77，且無反彈。溫度對找錯數、錯集合與殺傷力都沒有可見影響，溫度之間的差異與同一溫度重跑的雜訊相同（句子 Jaccard 0.23–0.26 對 0.22–0.24），批次放大四倍（n=20，23,000 句）仍然如此；但批次大小本身有影響，去重後的錯從 110 增到 273。以突變體為需求的縮減把 3,355 條測試縮到 196 條（5.8%）仍保留 100% 殺傷力，同大小隨機只有 54%；additional 排序的 APFD 為 0.985，跑前 10% 的測試就找到全部的錯。在舊版縮減的子集套到新版仍保留 84–85% 殺傷力（隨機 50%）；突變體的包含關係分析顯示 485 個可殺突變體裡只有 238 個（49%）是獨立的錯，一般突變分數把隨機子集高估一倍。真實使用紀錄當種子找到 4 個現行錯，3 個是缺規則，突變測試量不到；同一套工具跑在第二個受測對象（Home Assistant 的 520 條 zh-TW 意圖模板）上，縮減與排序的結論全部重現，但兩個受測對象錯的方向相反；第三個受測對象用 Gemini 當路由器，零調校就在自然改寫上比修了五輪的 regex 穩（2.7% 對 7.4%）、在模板句上輸（3.9% 對 0.5%），prompt 裡七成的例句與定義是等價突變體（拿掉例句不掉分、拿掉定義一致性違反翻倍），換大一號的模型錯的仍是同一批句子；縮減與排序的結論在 3 個受測對象 × 2 個模型 × 3 種 prompt 寫法下全部重現。人工標記 400 句顯示模型改寫 96.5% 保留原意圖（n=20 另抽 400 句：94.8%）、模板改寫 91.5%。

研究過程另有一個附帶發現：測試工具本身四次被自己的方法抓到錯（harness 標籤比對、種子含觸發詞、模型語意漂移、分析腳本去重順序），「測試工具自己也要測」成為本研究的實務結論之一。

壹、前言

一、研究動機

J.A.R.V.I.S. 是我自己寫的語音助理：對麥克風講一句話，它會開程式、播音樂、調音量、控制家電，或把話交給大型語言模型。為了省下 API 費用，它先用一層「本機路由」判斷這句話是不是簡單指令，是的話直接做，不是才送模型。這層路由是約 60 條正規表達式與關鍵字規則，每改一次都有對應的手寫測試，CI 全綠。

但實機使用時接連出事：「不要打開記事本」真的打開了記事本；「打開記事本好嗎」去找一個叫「記事本好嗎」的程式；「冷氣溫度調到 26 度」被天氣規則接走，回了一段天氣預報。三件事都是 CI 綠燈、上線後才發現。原因很清楚：輸入是自然語言，同一件事有無限種講法，手寫測試只能寫我想得到的幾種；而且沒有 oracle——沒人能列出所有句子的正確答案。

這就是軟體測試裡的四個經典問題：**該測什麼**（測試從哪裡來）、**測試多可靠**（測試本身會不會錯）、**留多少**（哪些測試是多餘的）、**先測哪些**（時間不夠時先跑哪些）。本研究用自己的產品當真實案例，把這四個問題做完整一輪，並把找到的錯修回產品。

二、研究目的與研究問題

編號	研究問題	怎麼回答
RQ1	蛻變關係自動生成的測試，能否找到手寫測試沒抓到的路由錯誤？模型生成與規則生成誰找得多、找得不一樣？	兩種生成器 × 五條關係，數違反、去重後的錯、人工標記改寫句的有效率
RQ2	生成參數（溫度）與模型非確定性對測試品質的影響	四個溫度 + 同溫度重跑三次，量句子重異、錯集合重異、殺傷力
RQ3	這些測試裡多少是多餘的？哪種縮減策略保留最多找錯能力？	自寫突變器 → 測試 × 突變體矩陣 → greedy / HGS / irreplaceable / 隨機
RQ4	只能跑前 k% 測試時，哪種排序最早找到錯？	同一矩陣：total / additional / 關係優先 / 隨機，APFD
RQ5	找到的錯修回去，路由變好多少？會不會修出新的錯？	修正前後五個版本重跑全部批次
RQ6	在舊版縮減 / 排序的測試集，程式改版後還有用嗎？	在 v4 的矩陣上決定，套到 v5 的矩陣上評估（反向也算）
RQ7	966 個突變體裡多少是獨立的錯？哪些運算子多餘？	突變體的包含關係、dominator 集、最小突變分數
RQ8	自己寫的種子跟真實使用差多少？真實指令找得到種子找不到的錯嗎？	使用紀錄裡的 41 條真實指令當第三批種子，比違反、比突變殺傷

編號	研究問題	怎麼回答
RQ9	以上結論是不是只對這一個 router 成立？	同一套關係、生成器、突變、縮減、排序跑在第二個受測對象（Home Assistant 的 zh-TW 意圖模板）上
RQ10	用模型當路由器，同一套測試會看到什麼？跟 regex 路由比，穩定度與成本差在哪？	Gemini 當 router（prompt 列 25 個意圖、回 JSON），同一套關係 / 縮減 / 排序；突變對象換成 prompt

RQ1、RQ2、RQ5、RQ8 屬於「測試生成」，RQ3、RQ4、RQ6、RQ7、RQ9、RQ10 屬於「測試集縮減與排序」，後者是本研究的主體。

貳、文獻探討

本研究用到四條線的文獻，每條只取跟本研究直接相關的部分。

一、蛻變測試（Metamorphic Testing）

Chen、Cheung 與 Yiu（1998）提出：當程式的正確輸出無法直接判定（oracle 問題）時，可以改檢查「多個輸入之間輸出應該滿足的關係」。例如 sin(x) 算不出標準答案，但 sin(x) 與 sin(π − x) 必須相等。對自然語言意圖路由來說，「同一句話換個講法應該走同一條路」就是一條蛻變關係，完全不需要知道正確答案。近年的自然語言處理測試研究大多建立在這個想法上：Ribeiro 等人（2020）的 CheckList 把「加無關前綴、換同義詞、語意不變則輸出不變」寫成對 NLP 模型的行為測試，本研究的 R1–R4 就是同一類的「不變性」關係，R5 則是它的「方向性期望」（改了意思、輸出就該變）。

二、突變測試（Mutation Testing）

DeMillo、Lipton 與 Sayward（1978）提出用「故意改壞程式」來評估測試集：每個被改壞的版本叫突變體，測試集能讓多少突變體失敗（殺掉）就是突變分數。Jia 與 Harman（2011）的總覽整理了運算子設計、等價突變體（改了但行為不變）與成本問題。通用工具（如 mutmut）只改運算子和常數，碰不到正規表達式字串裡的一個分支，所以本研究自寫運算子。

三、測試集縮減與排序

縮減（reduction）是在保留「需求覆蓋」的前提下挑出最小子集，本質是集合覆蓋（NP-hard），常用近似法有 greedy 與 Harrold、Gupta 與 Soffa（1993）的 HGS。林楚迪等人（2012、2014）提出先保留「不可取代的測試」（irreplaceable test：某個需求只有它能滿足）再貪心補齊的方法，以降低回歸測試成本；本研究把這三種策略與隨機對照都實作。排序（prioritization）則是 Rothermel 等人（2001）提出的：測試全部都要跑，但把最可能找到錯的排前面，用 APFD（平均錯誤偵測百分比）衡量；total 與 additional 是兩種最基本的排法。

四、用大型語言模型生成測試

近兩年用大型語言模型生成測試輸入成為熱門題目（Wang 等人 2024 的綜述整理了百餘篇，測試輸入生成是最大宗），其吸引力在於句型多樣，風險在於語意漂移（改寫後意思變了）與非確定性（同參數重跑結果不同）。本研究把這兩個風險分別用人工標記（E1）與重跑底線（E2）量化，並以模板生成器當對照組。

※ 文獻的完整書目列在參考文獻；林教授的兩篇論文已核對標題與年份，其餘經典文獻的卷期頁碼建議交稿前再核一次。

參、研究方法



研究流程 · 蛻變測試（上兩列）與突變分析（下列）共用同一批改寫句與同一個 router

圖一：上半部用蛻變關係把種子句改寫、拿 router 跑、判定違反，違反歸因後修 router 再跑全部批次；下半部把 router 本身改壞成突變體，用同一批改寫句算「測試 × 突變體」矩陣，縮減、排序、包含關係、跨版本轉移都從這張矩陣算。

一、受測對象與測試基座

受測對象是 J.A.R.V.I.S. 的 `jarvis/router.py`：輸入一句中文，經正規化（剝填充詞、客氣話、語助詞）後依序比對約 60 條規則，輸出是「目的地 + 目標」，例如 `open_application:記事本`、`youtube_play:晴天`、`home_control:冷氣=set=26`，或者「純問答」、「交給模型」。

為了能大量跑，寫了 `harness.py` 把路由變成純函數：所有會碰裝置、打 API 的出口都換成記錄器，`route_label("幫我開一下記事本")` 直接回標籤，一句約 0.1 毫秒。

二、蛻變關係

關係	改寫方式	路由結果應該
R1 同義改寫	打開 → 開啟 / 啟動 / 幫我開	與種子相同
R2 語助詞、禮貌詞	幫我…一下、…好嗎、…謝謝	相同
R3 換語序	記事本幫我開一下	相同
R4 無關前綴	欸、那個、JARVIS	相同
R5 近似句	不要打開記事本、記事本打不開怎麼辦	**不同**（不該觸發）

種子句 41 條（涵蓋 29 種目的地），後來從突變分析反推補 46 條，共 87 條。違反以「種子 × 關係 × 錯的目的地」去重後稱為一個「錯」，免得「打開記事本好嗎」與「打開記事本啦」算兩個。

三、兩種生成器

	規則式（對照組）	模型式
做法	模板：同義詞表、語助詞表、語序模板、近似句模板	Gemini 3.5 Flash-Lite，每條關係一段指令，輸出 JSON 陣列
變因	無	溫度 0、0.3、0.7、1.0；每個種子 × 關係生 5 句
成本	1 秒跑完	每批約 200 次 API 呼叫，有磁碟快取
過濾	長度 1–40 字；目標詞（程式名、歌名）必須還在句子裡	同左

三個指標：有效率（過濾後留下的比例）、違反率（有效句裡違反關係的比例）、多樣性（字元 bigram 的 distinct-2）。

指標的定義。種子 s 的路由為 route(s)，關係 R 對 s 的一句改寫 t 違反的條件是：

$$\mathrm{viol}(t) = \mathbf{1}[\,\mathrm{route}(t) \neq \mathrm{route}(s)\,] \quad (R1\text{–}R4), \qquad \mathrm{viol}(t) = \mathbf{1}[\,\mathrm{route}(t) = \mathrm{route}(s)\,] \quad (R5)$$

違反率只算有效句，去重後的「錯」以（種子, 關係, 實際路由到哪）為鍵；多樣性 dist-2 是不重複字元 bigram 占全部 bigram 的比例；兩批測試的重疊用 Jaccard，句子集合與錯集合各算一次；人工標記的一致性用 Cohen's κ：

$$\text{viol}\%_R = \frac{|\{t \in T_R : \text{valid}(t) \wedge \text{viol}(t)\}|}{|\{t \in T_R : \text{valid}(t)\}|}, \qquad \text{dist2} = \frac{|\text{unique bigrams}|}{|\text{bigrams}|}, \qquad J(A,B) = \frac{|A \cap B|}{|A \cup B|}, \qquad \kappa = \frac{p_o - p_e}{1 - p_e}$$

四、突變運算子

通用突變工具碰不到正規表達式字串的內容，所以自寫七種運算子，每種模擬一種意圖路由真的會犯的錯：

運算子	例子	模擬的錯
ALT_DEL	`(?:打開|開啟|開)` → 少一個分支	少收一個同義詞
LOOK_DEL	`開(?!心|會)` → `開`	忘了排除誤觸
OPT_DEL	`(?:幫我)?` → `(?:幫我)`	前綴從可選變必要
KW_DEL	關鍵字 tuple 少一個	詞表漏字
NUM	`len(text) <= 6` → 5 / 7	邊界值錯
CMP	`<=` → `<`	邊界值錯
BOOL	and ↔ or、刪 not	條件寫反

現行 router 產 927 個突變體。「殺」的定義：某條測試在原版路由到 X、在突變體路由到 ≠ X（或爆掉）。測試來源是種子加上各批次裡原版通過的句子，共 3,355 條，矩陣分四段跑，每段約 2 分鐘。

五、縮減與排序策略

縮減的「需求」有兩種：突變體（貴但準）與「關係 × 種子」（便宜，每格留一條）。策略四種：greedy（每次挑殺最多尚未被殺突變體的測試）、HGS、irreplaceable-first（先留唯一能殺某突變體的測試再質心補）、隨機（同大小，30 次取平均）。排序四種：total（殺傷數）、additional（每次挑殺最多尚未被殺的）、關係優先（R5 先）、隨機，指標是 APFD 與「跑前 k% 測試找到幾 % 的錯」。

設測試集 T、突變體 M（扣掉語法壞掉的），K(S) 為子集 S 殺掉的突變體，D 為 dominator 集（沒被更難殺的突變體包含的類）：

$$\text{MS}(T) = \frac{|K(T)|}{|M|}, \qquad \text{retain}(S) = \frac{|K(S)|}{|K(T)|}, \qquad \text{MS}_{\min}(S) = \frac{|K(S) \cap D|}{|D|}$$

排序的 APFD：測試 n 條、錯（可殺突變體）m 個，TF_i 是第 i 個錯第一次被殺時的測試位置：

$$\mathrm{APFD} = 1 - \frac{TF_1 + TF_2 + \cdots + TF_m}{n\,m} + \frac{1}{2n}$$

跨版本轉移（E7）把 S 在版本 A 的矩陣上決定、在版本 B 的矩陣上算 retain 與 APFD；dominator-APFD 把 m 換成 |D|。

六、實驗設計

實驗	回答	做法
E1 有效性人工標記	RQ1 的信度	每個生成器 × 關係抽 40 句，共 400 句（n=20 六批另抽 400 句），打亂順序、看不出來源，標 1 = 保留原意圖 / 0 = 意圖變了或句子不通
E2 非確定性底線	RQ2	同參數（T=0）真的重打 API 兩次，與溫度之間的差異放在同一把尺上比
E3 突變測試	RQ3 的 ground truth	全批次矩陣；存活突變體抽 60 個人工分類，每個判斷附一句能殺掉它的句子並用程式驗證
E4 縮減	RQ3	兩種需求 × 四種策略
E5 排序	RQ4	四種排序、APFD 曲線
E6 版本回歸	RQ5	同一批測試跑在 router 的六個歷史版本（直接 `git show`）
E7 跨版本轉移	RQ6	v4、v5 各算一份矩陣；在 v4 縮減 / 排序，套到 v5 評估保留率與 APFD，同大小隨機對照
E8 突變體包含關係	RQ7	kill vector 相同的歸同一類，類間的子集包含找 dominator；用 dominator 算最小突變分數
E9 真實使用種子	RQ8	從 ~/.jarvis/profile.json 的使用紀錄匯出 41 條不重複指令（83 次使用），中文的 24 條當種子跑規則式生成器與突變矩陣
E10 第二受測對象	RQ9	Home Assistant zh-TW 意圖（41 意圖、520 條模板，hassil 整句匹配）：64 條模板展開種子 + 1,010 條抽樣句；模板突變運算子（刪分支 / 可選變必要 / 刪 skip 詞）2,748 個突變體；同一套 reduce / subsume

實驗	回答	做法
E11 第三受測對象	RQ10	gemini-3.5-flash-lite、T=0，prompt 每個意圖一行（名稱｜定義｜ target 格式｜例句）+ 5 條規則；87 條種子問兩次量一致率；規則式批次與模型批次各路由一次；違反分「對期望」與「對自己對種子的路由」兩種基準；prompt 突變 80 個（刪意圖 / 例句 / 定義 / 規則）× 187 句
E12 RQ10 的通則檢驗	RQ10	換 prompt 寫法（noex 沒例句、names 只剩名稱和格式）與換模型（gemini-3.5-flash）各動一次，重跑種子一致率、兩種批次的一致性違反；flash 再跑一次 prompt 突變矩陣與縮減 / 排序

全部工具都在專案的 `research/mt/` 目錄，每個實驗一個指令就能重跑；工具的煩霧測試與存活突變體的 killer 驗證都進 CI。

肆、結果與討論

一、RQ1：蛻變測試找得到手寫測試沒抓到的錯

第一次規則式生成 928 句，一秒跑完，找到 433 個違反、去重後 83 個錯，全部是 CI 綠燈的手寫測試沒抓到的。

關係	生成	違反率	代表案例
R1 同義	48	14.6%	「開 github.com」走開程式而不是開網址
R2 語助詞	288	48.6%	「打開記事本好嗎」→ 目標變成「記事本好嗎」
R3 換語序	52	96.2%	「記事本幫我打開」→ 交給模型
R4 前綴	288	41.0%	「欸 開 YouTube」→ 交給模型
R5 近似句	252	46.8%	「不要打開記事本」真的打開記事本

模型生成器找到的去重錯是規則式的約兩倍（第一輪修正後 110 對 16），且兩者互補：規則式找到而模型沒找到的只剩 1–2 個。模型的優勢在 R3：模板只會產生「記事本幫我打開」這一種句型，模型會寫出「YouTube 這個 App 打開」「Chrome 幫我切過去」「26 度設定給冷氣」這些真人會講的句子。

人工標記（E1，400 句）量化了生成句本身的可靠度：

生成器	保留原意圖（precision）	標 0 的主因
模型（四溫度合計 200 句）	96.5%	偷加動作（「今天很開心可以幫我記下來嗎」）、換動詞（播晴天 → 搜尋晴天）
規則式（200 句）	91.5%	模板硬套出不通的句子（「我靜音都打不開怎麼辦」「執行下載資料夾」）
規則式 R5 近似句	70%	同上，R5 模板最容易套出不通句

扣掉無效句後，模型批次的違反率只從 13.0% 降到 11.4%：前幾輪找到的錯幾乎都是路由的錯，不是生成器的錯。規則式 R3 的 67.5% 違反也全是真的。模型漂移比規則式少，但漂得更隱蔽（加動作、換動詞），規則式漂得很明顯（句子不通）。

n=20 補抽（六批 _n20 各關係抽 80，共 400 句，同一位標記者）：保留原意圖 94.8%，比 n=5 的 96.5% 低 1.7 個百分點，掉的全在 R3 語序（100% → 87.5%）：後 15 句的語序改寫開始不通（「去哪走走好放假」「26度把它設在冷氣」）；R2 的 0 是模型多塞了一個動作（「麻煩幫我記錄今天過得挺開心的啦」）。扣掉無效句後違反率 14.5% → 13.7%：n=20 多找到的錯 94% 是真的（n=5 是 88%），批次放大沒有把漂移一起放大。

二、RQ2：溫度看不出影響，差異跟重跑雜訊一樣大

六批都用 41 條種子（每批 964 句）：四個溫度各一批，加上 T=0 真的重打 API 兩次。

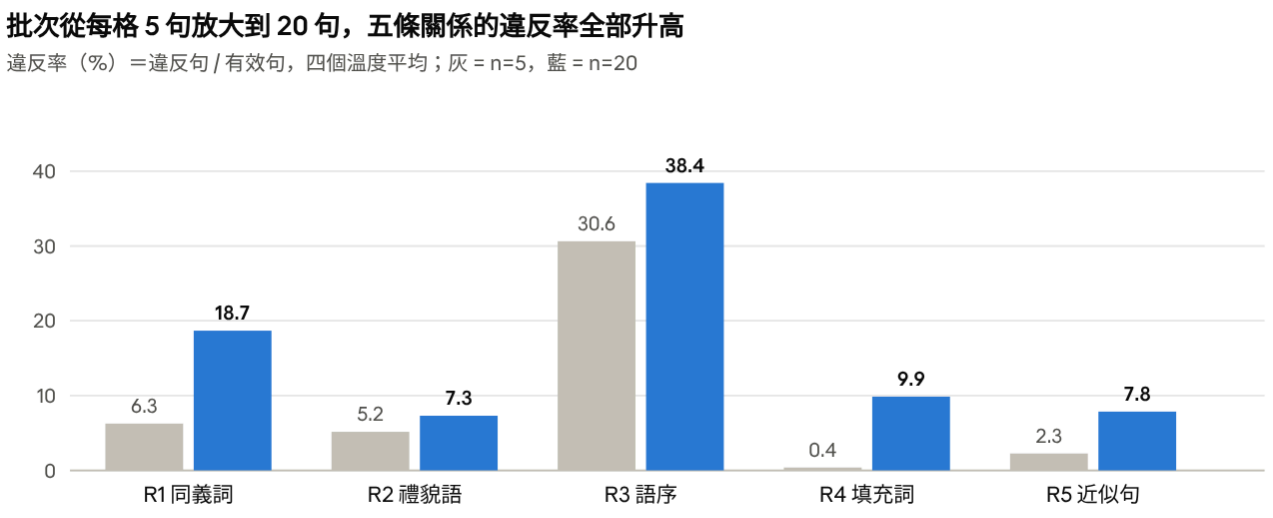
比較	句子 Jaccard	錯集合 Jaccard	共同的錯 / 只有一邊
溫度之間（6 對）	0.23–0.26	0.51–0.59	47–55 / 15–29
T=0 跑三次（3 對）	0.22–0.24	0.43–0.59	44–54 / 16–32
四個溫度全部共同的錯 / 聯集			38 / 116
T=0 三次全部共同的錯 / 聯集			39 / 115

三個結論。第一，T=0 不是確定性：重跑之間只有 22–24% 的句子一樣。第二，溫度之間的每個數字都落在重跑雜訊的範圍內，「四個溫度共同的錯 38/116」與「T=0 跑三次共同的錯 39/115」幾乎一樣，所以「不同溫度找到不同的錯」在這個規模下不成立。第三，殺傷力也一樣：四個溫度各殺 341 / 330 / 345 / 327 個突變體，T=0 三次殺 341 / 336 / 331 個。

這裡曾經出過一個分析錯誤：早期結果顯示「T0 殺 329 > T1 殺 243」，後來發現是測試去重時同一句只算給第一個批次，排最後的 T1 被少算一截；改成每句歸所有含它的批次後差異就消失了。任何用模型生成測試的比較（溫度、prompt、模型）都應該附這條重跑底線，否則差異可能只是抽樣。

把批次放大四倍（n=20）：溫度還是量不出來，但批次大小本身有影響。 n=5 的結論有個漏洞：可能只是批次太小看不出來。把每個種子 × 關係的句數從 5 加到 20，同樣六批（41 條種子、router v5）共 23,000 句：

	n=5（v5 重算）	n=20
每批句子	964	3,808–3,846
每批違反（T0 / T0.3 / T0.7 / T1）	91 / 94 / 77 / 94	623 / 645 / 656 / 653
T=0 三次違反	91 / 96 / 95	623 / 659 / 681
每批去重錯（四溫度 / T=0 三次）	51–70 / 60–67	167–182 / 179–182
錯集合 Jaccard：溫度之間 / 重跑之間	0.34–0.48 / 0.37–0.51	0.56–0.59 / 0.56–0.58
句子 Jaccard：溫度之間 / 重跑之間	0.23–0.26 / 0.22–0.24	0.17–0.18 / 0.17–0.18
四溫度聯集的錯 / 六批聯集	110 / 127	273 / 315
dist2（R1 / R3）	0.41 / 0.46	0.21 / 0.27



run.py 六批 n=5 與 n=20 · 41 條種子 · router v5 · 每條關係取四個溫度的平均

圖二：R3 語序本來就是最難的（30% → 38%），放大後漲最多的是 R1 同義詞（6% → 19%）和 R4 填充詞（0.4% → 10%）——前 5 句用的是常見同義詞和「欸 / 那個」，後 15 句才輪到「叫出來 / 點開」和「那個… / 嗯～」。

溫度的結論一字不改：n=20 四個溫度的錯 167–182、T=0 自己重跑 179–182，錯集合 Jaccard 溫度之間 0.56–0.59、重跑之間 0.56–0.58。但違反率從 9% 跳到 17%，去重錯從 110 變 273：**n=5 找到的 ~90 個違反是「模型最先想到的 5 種講法」，不是 router 的上限。** 多出來的錯我抽看了 T=0 那批新出現的 246 個違反，大多是真的：填充詞沒收（「那個…」「嗯…」「Jarvis 幫我」「欸～」，整句掉到模型）；禮貌語黏進目標（「打開下載資料夾拜託你了嗎」→ `open_folder:`

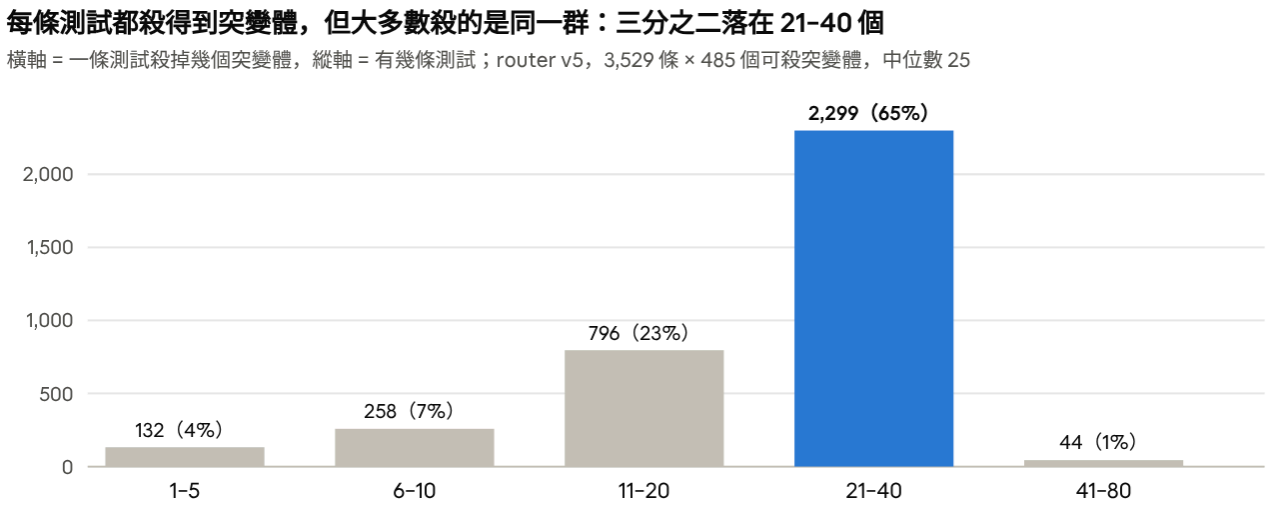
`下載資料夾拜託你了`；語序句更糟，「把記事本打開來」→ `open_application:來`、「播放歌手周杰倫的歌」→ `youtube_play:手周杰倫`）；R5 該擋沒擋（整句包含種子片語的問句照樣觸發：「音量調大是要按哪個按鈕」、「以圖搜圖怎麼用」、「我剛剛不小心按到靜音了」；「取消前往 github.com」照開）。漂移是少數（「我想聽歌開心一點」路到播歌其實合理）。代價是 dist2 砍半、句子 Jaccard 從 0.24 掉到 0.17：後 15 句彼此很像，23,000 句裡只有 315 個不同的錯。違反的性質也變了：T=0 那批掉到模型的佔 55%（n=5 時 43%）——放大批次多撈到的主要是「該觸發沒觸發」這種安全的錯。注意 E1 的有效率 96.5% 是 n=5 量的，n=20 的尚未標記。

三、RQ3：縮減到 5.8% 仍保留全部殺傷力，但便宜準則等於隨機

主矩陣：3,355 條測試 × 927 個突變體，殺 482，突變分數 0.520。

需求	策略	縮減後大小	保留的殺傷力	同大小隨機（30 次）
突變體	greedy	202（6.0%）	100%	54.2% ± 1.8
突變體	HGS	196（5.8%）	100%	53.7% ± 1.9
突變體	irreplaceable-first	196（5.8%）	100%	53.5% ± 1.7
關係 × 種子	greedy / irreplaceable	420（12.5%）	60.4%	66.5% ± 2.0
關係 × 種子	HGS	420（12.5%）	67.2%	66.7% ± 1.8

以突變體為需求時，三種策略幾乎一樣好：留 6% 的測試就能殺掉全部原本殺得掉的突變體，而隨機挑同樣多只剩一半。以「關係 × 種子」這種不用跑突變測試的便宜準則時，縮減結果跟隨機沒有差別：「每格留一條」不知道哪條有鑑別力。要縮減就要先花錢算突變矩陣。



mutation.py 主矩陣（router v5）· 每條測試的殺傷數分組計數

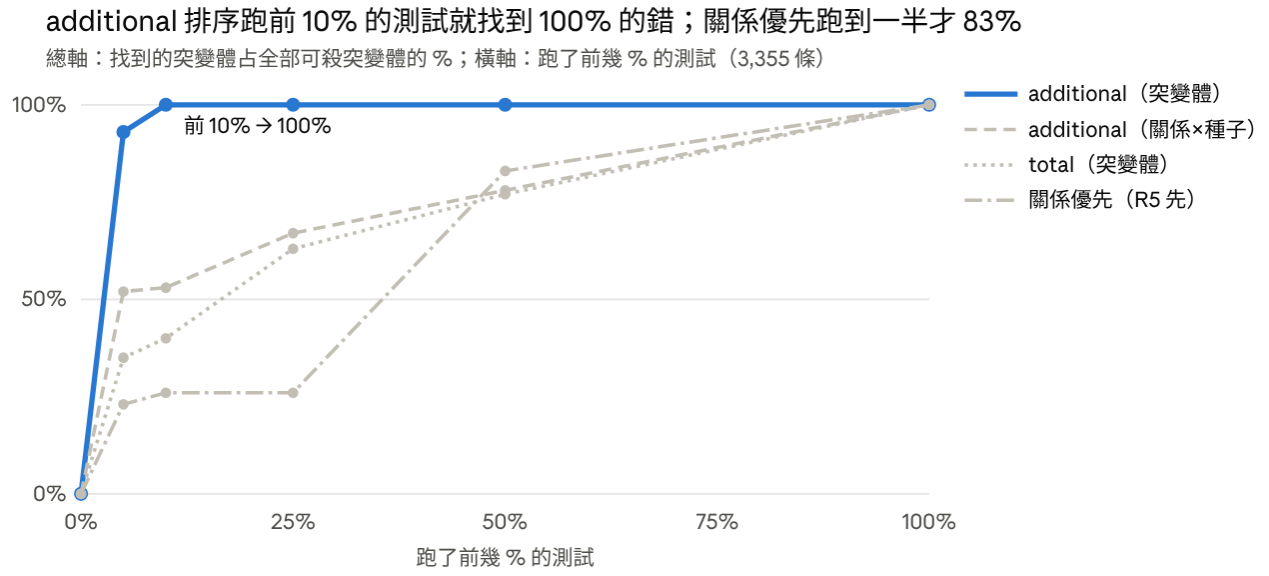
圖三：沒有一條測試是廢的（最少也殺 1 個），但分佈集中在 21–40——這些測試殺的是同一群「誰都殺得到」的突變體（正規化層、常用規則），所以留 6% 就能保留 100% 殺傷力；左邊 1–5 那 132 條才是專門守某條 regex 的。

存活突變體的人工分類（抽 60 個）：沒覆蓋 77%、等價 18%、測試基座看不到 5%；扣掉等價後突變分數約 0.51。0.52。每個「沒覆蓋」的判斷都附一句能殺掉它的句子並用程式驗證：第一輪人工判斷 57 個錯了 19 個（33%），大多是句子被另一條規則接住。把這 46 句補成種子後突變分數從 0.448 升到 0.516；46 句殺 191 個突變體，比原本 41 條種子（156）多。而規則式再對這 46 句生 718 句改寫只多殺 2 個：改寫換的是句型，突變體改的是詞表，兩者正交。

四、RQ4：additional 排序跑前 10% 就找到全部的錯

排序	APFD	跑前 5%	前 10%	前 25%	前 50%
additional（突變體）	**0.985**	93%	100%	100%	100%
隨機（30 次）	0.836 ± 0.009				
additional（關係 × 種子）	0.783	52%	53%	67%	78%
total（關係 × 種子）	0.744	54%	55%	58%	75%
total（突變體）	0.729	35%	40%	63%	77%
關係優先（R5 先）	0.694	23%	26%	26%	83%

total 輸給隨機是教科書結果：殺最多的測試彼此重複，排在前面的前 100 條在殺同一群突變體。關係優先最差：近似句找到的錯最危險（該擋沒擋），但它們對 regex 的可變點沒有施力，殺的突變體少。



reduce.py 在主矩陣（3,355 條 × 927 個突變體）的輸出 · 隨機排序 APFD 0.836，曲線略

圖四：曲線越快貼到 100% 越好，曲線下面積就是 APFD。

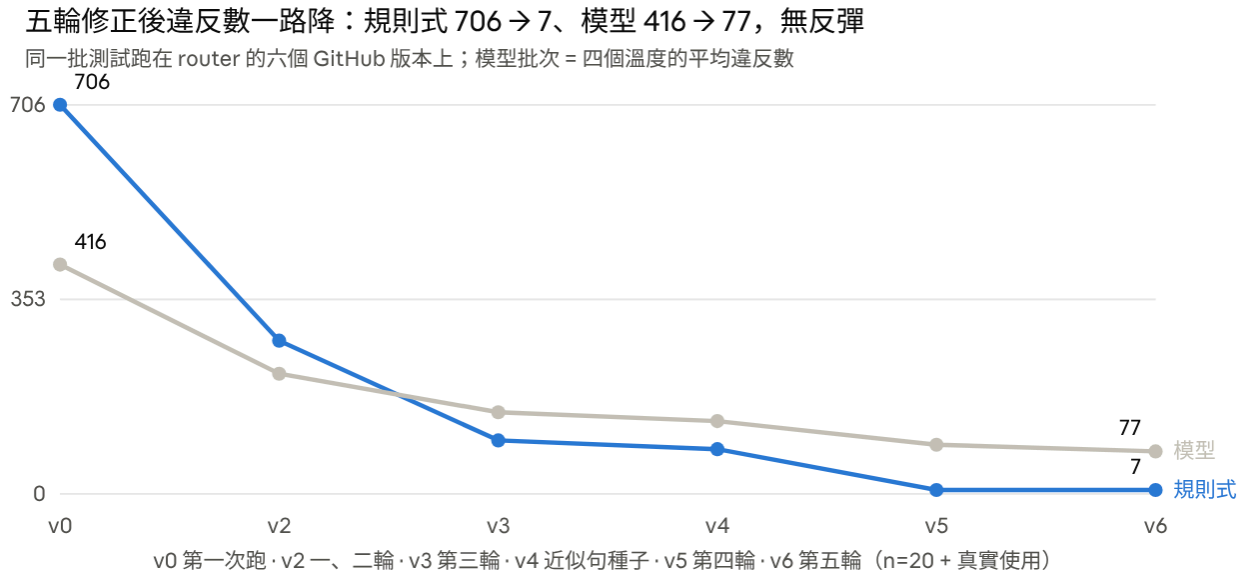
五、RQ5：五輪修正違反一路降、無反彈；突變分數要看分子，也要看測試集有沒有跟上

同一批 3,529 句測試跑在 router 的六個歷史版本上（GitHub main 的 commit；第一輪沒有單獨的 commit，跟第二輪一起推上去）：

版本	種子答對（41 / killer 46）	規則式 違反 / 錯	T0	T0.3	T0.7	T1	突變分數（殺 / 可用）
v0 `c060593` 第一次跑	39 / 23	706 / 172	413 / 164	420 / 170	423 / 165	407 / 165	0.468（175 / 374）
v2 `1352fae` 一、二輪	39 / 28	278 / 80	219 / 119	222 / 126	219 / 114	211 / 121	0.518（314 / 606）
v3 `0810b4d` 第三輪	39 / 45	97 / 35	148 / 78	147 / 76	147 / 72	149 / 84	0.513（444 / 865）
v4 `7040c54` 近似句種子	41 / 46	81 / 32	131 / 70	133 / 69	128 / 69	134 / 79	0.516（441 / 854）
v5 `3f5e658` 第四輪	41 / 46	**7 / 5**	91 / 60	94 / 61	77 / 51	94 / 70	0.502（485 / 966）
v6 `db00e03` 第五輪	41 / 46	7 / 5	71 / 49	85 / 57	72 / 49	80 / 60	0.417（467 / 1,120）；加 n=20 六批 0.500（560）

三個觀察。第一，違反數一路降：規則式 706 → 7、模型批次約 415 → 約 90，且沒有反彈；第二輪曾把報時規則修得太嚴、第四輪第一版新壞 3 句，都是被蛻變測試批次當回歸集抓回來、在同一次修正內解決。第二，四個溫度在每一版的違反數都幾乎一樣（同版內差 < 6%），與 RQ2 一致。第三，突變分數 v0–v5 都約 0.5，但可用突變體從 374 增到 966：router 每修一輪就多收一批詞，每個新詞是新的可變點，測試集跟著長比值才沒掉；看絕對數，殺掉的突變體從 175 增到 485。突變分數是比值，受測對象在長的時候要看分子。

第五輪（v6）是把 n=20 六批的 315 個錯和真實使用的 4 個錯修回去：同一批句子的違反從 4,069 降到 2,919（修掉 1,150、零回歸），真實使用批次 54 → 3，模型 n=5 批次約 90 → 77。修的過程中三次被回歸集抓到（「到底」進問句守門害「剪貼簿裡到底有什麼」掉到模型；「囉」進尾語害「哈囉」不是招呼；「點開」進開程式觸發詞害「點開心一點」變成開程式），都在同一次修正內解決。但 v6 用原矩陣（n=5 六批）算的突變分數掉到 0.417：第五輪加了 154 個可變點（填充詞 / 尾語 / 問句守門的詞表），會殺這些新分支的句子在 n=20 批次裡，不在矩陣裡；殺掉的絕對數還少了 18 個，因為像「刪掉怎麼說」這種突變體被整句的「怎麼」守門蓋住，變成等價。把 n=20 六批加進矩陣（13,879 條不重複句 × 1,120 個突變體），分數回到 0.500（殺 560），殺掉的絕對數 485 → 560。規則長了，測試集也要跟著長，分數才有意義。



versions.py 輸出與第四輪重跑結果 · 規則式 1,373 句，模型每批 964 句

圖五：模型批次在 v3 後持平、v5 才再降，因為第四輪才處理 R3 語序——模型批次一半的違反都是語序；v6 再降到 77，剩下的是漂移和長尾。

六、RQ6：在舊版縮減的測試集，新版還保留 85% 殺傷力（隨機 50%）

E4 的「縮減後保留 100%」是在同一份矩陣上自己對自己。回歸測試真正的問題是：縮減在 v4 決定，程式改到 v5 之後，那份子集還殺不殺得到 v5 的錯？做法是兩個版本各自產突變體、各算一份矩陣（同一批 3,529 句測試），在 v4 的矩陣上縮減與排序，套到 v5 的矩陣上評估。

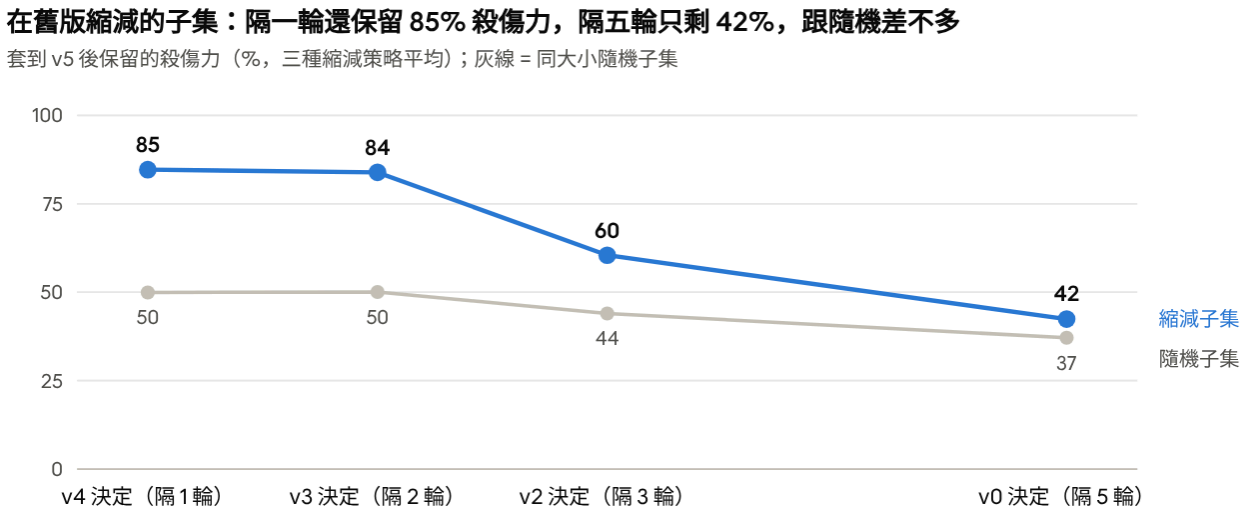
在 v4 決定 → 套到 v5	大小	在 v4 保留	在 v5 保留	同大小隨機（v5）
greedy	190	100%	**84.3%**	50.7% ± 2.0
HGS	183	100%	**85.2%**	49.4% ± 2.2
irreplaceable-first	184	100%	**84.5%**	49.7% ± 2.5

排序（在 v4 決定）	APFD@v4	APFD@v5
additional	0.986	**0.901**
total	0.730	0.760
關係優先	0.701	0.642
隨機	—	0.820 ± 0.009

反向（v5 決定 → 套到 v4）三種縮減保留 89–90%（隨機 54%）、additional 0.954。縮減子集在 v5 掉的 15% 全是 v5 新 regex（受詞在前的 `_OBJ_FIRST_RE` 等）的突變體：舊版決定的子集不可能涵蓋新版才出現的可變點，這是任何縮減法的上限，不是策略的問題；三種策略轉移後仍然一樣好。實務上的意思：縮減後的子集可以跨版本用，但 router 每加一條規則就要把守它的 killer 種子補進去。

版本距離越遠掉越多（都套到 v5）：

在哪版決定	隔幾輪	縮減子集在 v5 保留	同大小隨機	additional APFD@v5	隨機 APFD
v4	1	84–85%	50%	0.901	0.82
v3	2	84%	50%	0.900	0.82
v2	3	60–61%	44%	0.797	0.82
v0	4	41–43%	37%	**0.716**	0.82



transfer.py · v4 / v3 / v2 / v0 各自縮減後套到 v5 · 隨機子集 30 次平均

圖六：隔一、兩輪幾乎不掉（v4、v3 都 84%），第三輪起急降——第三輪把鎖定 / 切換 / 家電的 regex 整個重寫，舊版選出來的句子對新 regex 的分支沒有鑑別力。

v3 → v5 跟 v4 → v5 幾乎一樣，因為第四輪只加 regex 沒動舊的；v2 → v5 掉到 61%，因為第三輪改寫了鎖定 / 切換 / 媒體鍵的規則，舊子集守的是已經不存在的可變點。隔四輪之後 additional 排序比隨機還差（0.716 對 0.82）：它把「在 v0 殺最多」的測試排前面，那些測試守的規則在 v5 早就改掉了；total 反而穩（0.73–0.76），因為它本來就沒在利用版本特定的資訊。排序比縮減更怕過期。

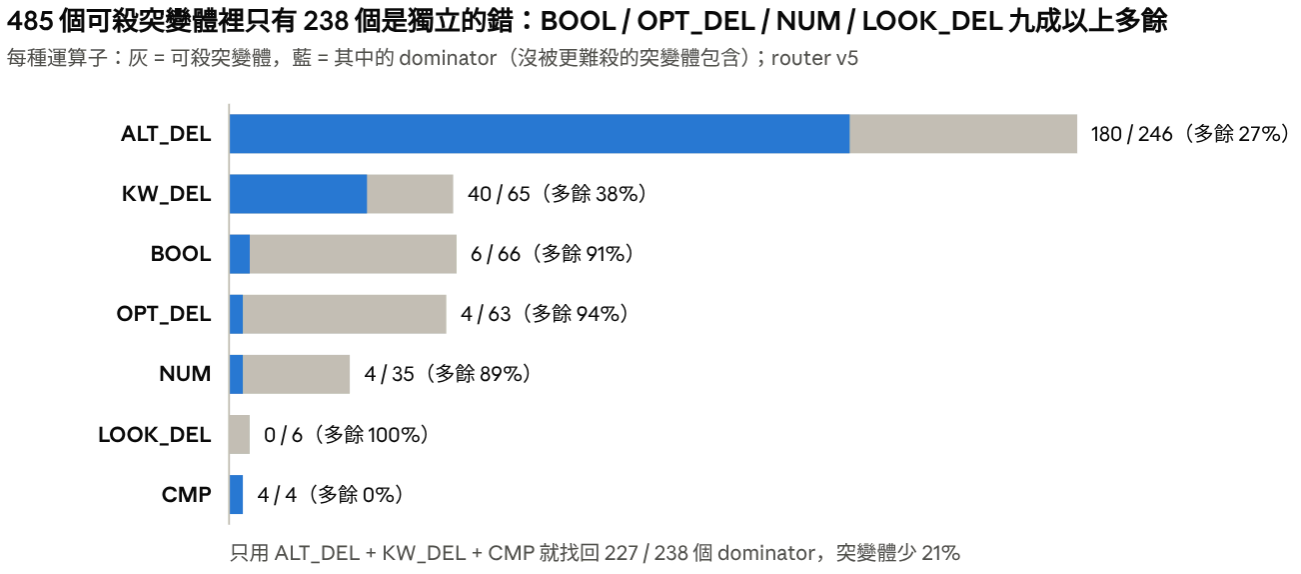
第五輪（v5 → v6，加了 154 個可變點）再算一次，用看得到新分支的 13,879 句全集：在 v5 縮減的 272–275 條套到 v6 保留 94.5–95.5%（同大小隨機 43%），additional APFD 0.981（隨機 0.867）；反向 93%。隔一輪掉 5%，比 v4 → v5 的 15% 少：第四輪加的是整條新 regex，舊子

集沒有句子碰得到；第五輪加的是既有 regex 的詞表，守舊詞表的句子有一部分順便碰到新詞表。只用 n=5 的 3,529 句評估會看到 97%，那不是更好，是那些句子碰不到 v6 的新分支（可殺 485 → 467）——轉移評估要用看得到新分支的測試集，否則新版的洞不會被算進分母。

七、RQ7：966 個突變體裡只有一半是獨立的錯

兩個突變體被同一群測試殺，對測試集來說是同一個錯；殺 m 的測試都殺 n，n 就多餘。沒被更難殺的突變體包含的叫 dominator，用 dominator 算的最小突變分數不會被同一個錯的多個突變體灌水。在 v5 的矩陣上：485 個可殺突變體、413 個 kill vector 不同、**238 個（49%）是 dominator**。

運算子	可殺	dominator	多餘比例
ALT_DEL（刪 regex 分支）	246	180	27%
KW_DEL（關鍵字表少一個）	65	40	38%
CMP	4	4	0%
BOOL	66	6	**91%**
OPT_DEL	63	4	**94%**
NUM	35	4	**89%**
LOOK_DEL	6	0	**100%**

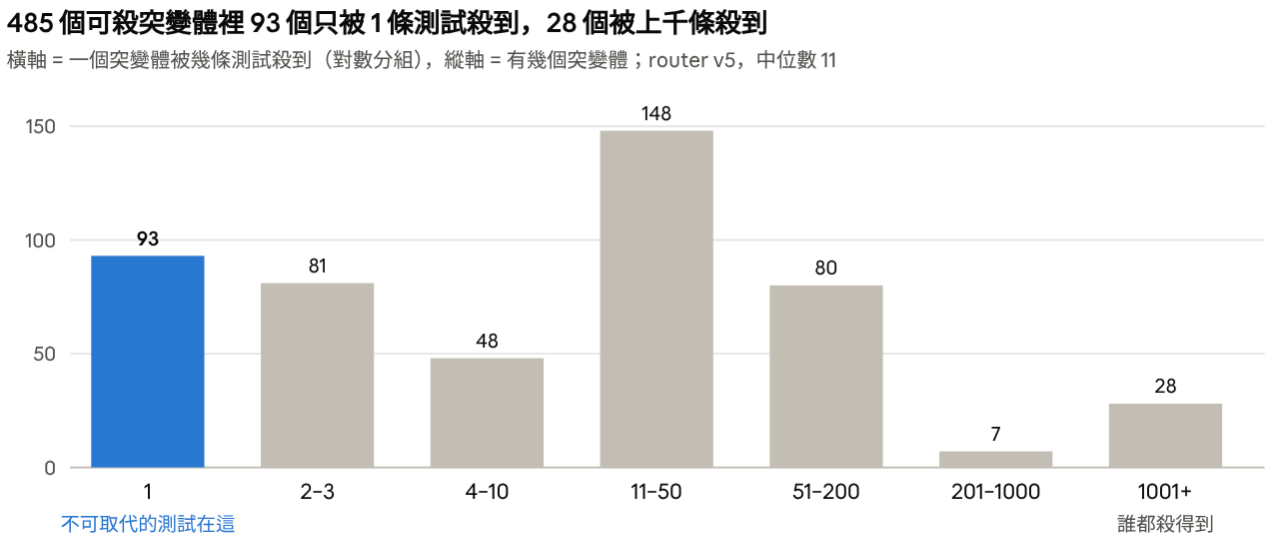


subsume.py · router v5 的 966 個突變體 × 3,529 條測試

圖七：改詞表的突變體（ALT_DEL、KW_DEL）才是獨立的錯；改運算子、邊界、可選群組的幾乎都被詞表突變體順便殺掉。

測試子集	大小	一般分數	最小分數
greedy / HGS / irreplaceable	212–215	100%	100%
同大小隨機	212–215	52%	**27%**
additional 前 2%	70	68.7%	38.2%
additional 前 5%	176	92.0%	83.6%
additional 前 10%	352	100%	100%

三個結論。第一，一般突變分數灌水兩倍：隨機子集在一般分數下看起來有 52%，用最小分數只有 27%，縮減策略與隨機的差距比 E4 的表還大。第二，運算子有輕重：改運算子、邊界、可選群組的突變體九成以上被改詞表的突變體包含，只用 ALT_DEL + KW_DEL + CMP 就能得到幾乎一樣的 dominator 集，突變體少 44%。第三，最難殺的 dominator 全是第四輪新 regex 的分支，每個只被 1 條測試殺——那 1 條就是 golden test 或 killer 種子，這些才是測試集裡真正不可取代的測試。



mutation.py 主矩陣（router v5）· 每個可殺突變體被幾條測試殺到，對數分組

圖八：兩頭重。左邊 93 + 81 個只被 1–3 條測試殺到，那幾條就是 golden test 或 killer 種子，縮減時一定要留；右邊 28 個被上千條殺到（改正規化層的突變體），每條測試都順便殺掉它們，也是「一般突變分數灌水」的來源。

用 dominator 重看 E4 / E5：只用 ALT_DEL + KW_DEL + CMP 產突變體（765 個、可殺 315）就找回 227 / 238 個 dominator，三種縮減子集 202–204 條仍保留 100%，同大小隨機的最小分數同樣是 27%——突變體少了五分之一、可殺少三分之一，結論不變。

排序	APFD（全部突變體）	APFD（dominator）
additional	0.984	0.972
隨機	0.824	0.715
total	0.772	0.685
關係優先	0.645	0.520

以 dominator 類當「錯」算 APFD，排名不變、差距拉大：additional 幾乎不掉，total 與隨機掉 0.09–0.11，關係優先掉到 0.52——它們排前面的測試殺的是同一群多餘突變體。

在 v6 的全矩陣（13,879 句 × 1,120 個突變體）重算：560 個可殺裡 307 個（55%）是 dominator，比 v5 的 49% 高——n=20 的句子把一些原本被同一群測試殺的突變體分開了（ALT_DEL 多餘 27% → 19%），但 OPT_DEL / BOOL / NUM / LOOK_DEL 九成多餘的結論不變。測試多四倍，縮減比例從 6% 掉到 1.8%（250–256 條保留 100%），同大小隨機的最小分數從 27% 掉到 18%：測試集越大，隨機抽樣越沒用、縮減越值得。additional 排序前 2%（277 句）就殺光 560 個，跟 greedy 子集幾乎同大小——排序的前段就是縮減子集。最難殺的 dominator 換成第五輪的詞表分支，各 1 條測試殺：每輪新加的規則都會變成下一輪最不可取代的測試。

八、RQ8：真實使用找到的 4 個錯，3 個是「缺一條規則」，突變測試永遠量不到

前面 87 條種子都是我寫的（41 條憑印象、46 條對著存活突變體補）。第三批從使用紀錄（`~/.jarvis/profile.json` 的 history）匯出：使用者實際講過的 41 條不重複指令，共 83 次使用。其中 11 條（27%）是英文（Open insta、Play rickroll on yt、Can u shut down the laptop），router 一律交給模型；中文的 24 條當種子。

真實指令（使用次數）	現行路由	應該	為什麼 87 條種子沒抓到
搜尋瑞克搖並播放（3）	google 搜尋「瑞克搖並播放」	youtube_play:瑞克搖	「搜尋 X 並播放」是手機頁的功能，router 沒有這條規則
下載Spotify於桌面	install_app:Spotify於桌面	install_app:Spotify	目標後面接地點，種子都沒有
開啟螢幕	open_application:螢幕	交給模型	「螢幕」不是程式；開程式規則對目標不設防
截取看看這是什麼	純問答	camera_search	「截取」這個動詞沒收

規則式生成器對 24 條真實種子生 390 句、54 個違反，全部來自這 4 條種子本身就錯（其餘 20 條零違反）。突變殺傷：真實批次 336 句殺 147 個突變體，其中只有 3 個是現有 3,529 條殺不掉的——「有哪些裝置」（使用次數第二高的指令，之前零覆蓋）、「框選」、「天氣」三個關鍵字。

兩個結論。第一，突變測試量不到「缺的規則」：4 個真實錯裡 3 個是 router 沒有那條規則，突變體只能改現有規則，產生不出「缺一條規則」的錯，所以突變分數 0.52 不代表路由只錯一半，缺口只有真實使用量得到。第二，種子偏誤是真的但有限：curated 種子的殺傷覆蓋了真實使用的 98%（147 裡的 144），但真實使用 27% 是英文、最常用的指令之一完全沒測到——覆蓋率高只是因為種子跟規則是同一個人寫的。

九、RQ9：換一個別人寫的路由器，縮減 / 排序的四個結論全部重現，但「哪種突變體多餘」跟寫法有關

前面所有數字都來自一個 router，而且種子、規則、突變運算子都是同一個人寫的。第二個受測對象選 Home Assistant 的 zh-TW 意圖模板：正式產品在用、別人寫的、繁體中文、41 個意圖 520 條模板。它跟 router.py 一樣是「規則 → 意圖」，但實作相反：router 是正規表示式在句子裡找關鍵字，hassil 是模板要整句精確匹配（只靠 skip_words 忽略 請 / 請問 / 謝謝 / 幫我 / 告訴我）。模板語法 (a|b) / [可選] / <rule> 跟我的突變運算子一一對應，所以同一套關係、生成器、縮減 / 排序、包含關係分析原封不動跑上去（`run.py --subject hass`、`hass_mutation.py`）。種子 64 條從模板自動展開，另用 hassil 的抽樣器對每個意圖最多抽 40 句（1,010 句）當「使用者會講的句子」的替身。

蛻變測試：同一套關係，錯的方向相反。 規則式生成器對 64 條種子生 985 句，596 個違反（60%）；router v5 同一個生成器只有 7 個。

關係	生成	違反	HA 怎麼錯	router 怎麼錯（v0 → v5）
R1 同義詞	13	7（54%）	「啟動 / 執行客廳燈」不收；另 3 句是我的生成器把「開始除草」改成「打開始除草」，生成器的錯	15% → 0
R2 禮貌語	320	260（81%）	句尾 一下 / 好嗎 / 可以嗎 / 喔 全部 → none；只有「謝謝」在 skip_words 裡過得了	49% → 0
R3 語序	12	9（75%）	「客廳燈，打開」→ none；「客廳燈幫我打開」→ HassGetState（問燈開了沒）：skip 掉「幫我」後剩「客廳燈打開」，撞到問狀態的模板	96% → 0
R4 填充詞	320	320（100%）	句首 欸 / 那個 / 嗯 一律 → none	41% → 0

關係	生成	違反	HA 怎麼錯	router 怎麼錯（v0 → v5）
R5 近似句	320	0	整句匹配，不在模板裡的句子都是 none，不會誤觸發	47%（「不要打開記事本」真的打開）→ 0

run.py 規則式生成器 · router v0 928 句（第一次跑）與 Home Assistant 985 句

圖九：router 五條關係都會錯，Home Assistant 只錯在「該觸發沒觸發」的四條——整句匹配的實作天生不會誤觸發，代價是講法稍有不同就聽不懂。

整句匹配的 HA 只會「該觸發沒觸發」（R2 / R3 / R4），永遠不會 R5；找關鍵字的 router 兩種都會，v0 時 R5「不該觸發也觸發」佔一半。HA 的 R2 / R4 違反是設計取捨（寧可不懂也不要亂做），但「客廳燈幫我打開 → 問狀態」是真的錯：使用者要開燈，它回答燈開了沒。

突變、縮減、排序、包含關係：結論一樣。 模板突變體 2,748 個（ALT_DEL 1,031、OPT_DEL 1,634、RULE_ALT_DEL 73、RULE_OPT_DEL 4、SKIP_DEL 6），矩陣 1,454 條測試 × 2,748 個突變體跑 8 分鐘。

	HA	router v5（RQ3 / RQ4 / RQ7）
測試	1,454（64 種子 + 1,010 抽樣 + 380 規則式改寫）	3,529
突變體 / 可殺（分數）	2,748 / 400（0.146；只用 64 種子時 175，0.064）	927 / 485（0.52）
dominator	259（65%）	238（49%）
運算子多餘比例	OPT_DEL 51%、RULE_ALT_DEL 34%、ALT_DEL 11%	OPT_DEL 94%、BOOL 91%、ALT_DEL 27%
縮減（需求 = 突變體）	→ 186–187 條（12.9%）保留 100%；同大小隨機 43%	→ 212–215 條（6%）保留 100%；隨機 52%
同大小隨機的最小分數	43%	27%
縮減（需求 = 關係 × 種子）	→ 1,193 條（82%）保留 94%；隨機 96%	→ 222 條保留 56–60%；隨機 57%
APFD：additional / total / 隨機 / 關係優先	0.956 / 0.790 / 0.746 / 0.634	0.984 / 0.772 / 0.824 / 0.645

	HA	router v5（RQ3 / RQ4 / RQ7）
APFD（dominator）：additional / total / 隨機 / 關係優先	0.944 / 0.739 / 0.753 / 0.569	0.972 / 0.685 / 0.715 / 0.520
additional 前 10% 測試找到	89%（dominator 83%）	100%

四個觀察。第一，排序與縮減的結論一字不改：additional 最好、關係優先最差，dominator 分數下差距更開；三種縮減策略一樣保留 100%，隨機只有 43%，「關係 × 種子每格留一條」等於隨機。唯一的差別是 total 在 HA 上小贏隨機（0.790 vs 0.746），在 router 上輸。第二，突變分數低是因為測試少，不是突變體壞：64 條種子只殺 6%，加 1,010 句抽樣後 15%，520 條模板的分支絕大多數沒有句子碰到——跟 RQ3 的教訓一樣，存活體在列種子缺什麼。第三，哪種突變體是獨立的錯取決於實作：router 的 OPT_DEL 94% 多餘（可選群組幾乎都被詞表突變體順便殺），HA 的 OPT_DEL 只有 51%、ALT_DEL 只有 11%，因為整句匹配下 [的] 變必要就讓「打開客廳燈」整句失敗，是獨立的錯。RQ7「以後只跑 ALT_DEL + KW_DEL + CMP」的省時建議只對正規表示式類的受測對象成立。第四，R5 在 HA 上零違反、殺傷也幾乎沒有（320 句裡只有 17 句殺得到突變體）：辨識成 none 的句子，模板怎麼刪都還是 none。關係優先排序在 HA 上最差就是因為它把這 320 句排前面。

限制：HA 的種子是從模板展開的，不是真實使用（RQ8 那種缺口量不到）；模型生成器沒跑；裝置清單是我固定的 9 個名稱。

十、RQ10：零調校的模型路由在自然改寫上比修了五輪的 regex 穩，在模板句上輸；prompt 裡七成的例句是等價突變體

第三個受測對象把意圖清單寫進 prompt（25 個意圖，每個一行「名稱｜定義｜ target 格式｜例句」，加 5 條全域規則），每句話交給 gemini-3.5-flash-lite（T=0）回 `{"kind", "target"}`，標籤空間跟 router.py 一樣。沒有調校：prompt 寫完就跑。

種子與非確定性。 87 條種子答對 78（90%）：錯的 9 條裡 2 條是 prompt 漏列意圖（download_file、list_windows）、3 條可爭議（「開 YouTube」→ open_url:youtube.com、問快速鍵 → info 而非 model）、4 條真錯（「用電腦打開記事本」沒切裝置、「現在才要打開記事本」照開）。同句問兩次 86 / 87 一致（「播報新聞」在 info 與 model 之間翻）——T=0 仍不是確定性，跟 RQ2 的生成器一樣。

違反要分兩種基準算。 對「期望路由」算，規則式批次 114 個違反，但 81 個來自那 9 條種子本身答錯——這把「準不準」和「穩不穩」混在一起。改對「受測對象自己對種子的路由」算（`--baseline own`，只量一致性）：

批次	模型路由（對自己）	regex v6（同一批）
規則式 1,373 句	52 / 1,339（3.9%）：R2 21 / 430、R4 14 / 430、R5 7 / 330、R3 7 / 76、R1 3 / 73	7（0.5%）
模型 T0 n=5	25 / 941（2.7%）	71（7.4%）

零調校的模型路由在自然改寫上比修了五輪的 regex 穩（2.7% 對 7.4%），在模板句上輸（3.9% 對 0.5%）——regex 的 0.5% 是五輪對著這批修出來的，模型沒看過任何一句。模型的錯有兩型：把「可以嗎」當問句（「音量調大可以嗎」→ info），和整句包含指令就做（「播晴天會怎樣」照播）——後者跟 regex v5 以前的 R5 錯同一型。最有意思的是「開 YouTube」：種子本身答 open_url，「欸 開 YouTube」「YouTube 幫我開」「啟動 YouTube」全部答 open_application——種子才是異類，蛻變關係兩個方向都抓得到；regex 不會出這種錯，同一條規則永遠給同一個答案。

prompt 突變。 刪 regex 分支的對應物是刪 prompt 的一行：INTENT_DEL（刪一個意圖）、EX_DEL（刪例句）、DEF_DEL（刪定義）、RULE_DEL（刪一條全域規則），80 個突變體 × 187 句（87 種子 + 規則式每關係抽 20）= 1,496 次 API、22 分鐘。

運算子	突變體	殺	dominator
INTENT_DEL 刪一個意圖	25（1 個沒測試碰到）	24 / 24	16
EX_DEL 刪例句	25	7	5
DEF_DEL 刪定義	25	6	5
RULE_DEL 刪一條規則	5	5	0

刪意圖一定被殺（刪功能），而且 date / math / lens / hide / weather 各只靠 1 句殺；**七成的例句和定義拿掉模型照樣答對**——它從名稱就知道 open_application 是什麼，這些是 prompt 裡的等價突變體；有用的定義是 info / model / set_volume 這種邊界。刪規則殺得到但每條只被 3–7 句殺、全部被 INTENT_DEL 包含：規則對模型是加分，不是開關。突變分數 0.525、dominator 62%；縮減 187 → 25（13.4%）保留 100%（同大小隨機 43%）；APFD additional 0.955、total 0.886、隨機 0.741、關係優先 0.740；dominator-APFD additional 0.936、隨機 0.652。三個受測對象（regex、整句匹配、模型）的縮減與排序結論一樣；不一樣的是「什麼叫一個獨立的錯」：regex 是一個分支、模板是一個可選群組、prompt 是一個意圖。

成本是真正的取捨：模型路由每句上線都要一次呼叫（每句約 0.9 秒），突變矩陣 80 × 187 要 1,496 次 API；regex 的 966 × 3,529 離線 2 分鐘。限制：只試一個溫度（模型與 prompt 寫法各換了一次，見下面的 E12）；突變矩陣的測試只有 187 句；改意圖 X 的突變體只重跑原版路由到 X 的句子（跟 RQ9 同一個近似）。

通則檢驗（E12）：換 prompt 寫法、換模型。 上面只有一個模型（gemini-3.5-flash-lite）和一個 prompt 寫法。E12 把兩個變因各動一次：prompt 改成沒例句（noex）、只剩名稱和輸出格式（names）；模型換成同家族大一號的 gemini-3.5-flash。看三件事變不變：種子準確率與一致率、一致性違反率（`--baseline own`）、「例句 / 定義是等價突變體」。

設定	種子答對	同句兩次一致	規則式批次一致性違反	模型批次一致性違反	prompt 突變 殺 / 80（INTENT / EX / DEF / RULE）	縮減 187 → 25 保留	APFD additional
flash-lite · full	78 / 87	86 / 87	52 / 1,339（3.9%）	25 / 941（2.7%）	42（24 / 7 / 6 / 5）	100%	0.955
flash-lite · noex	**80 / 87**	84 / 87	58 / 1,347（4.3%）	32 / 961（3.3%）	—	—	—
flash-lite · names	75 / 87	85 / 87	**83 / 1,376（6.0%）**	**51 / 963（5.3%）**	—	—	—
flash · full	77 / 87	86 / 87	88 / 3,590（2.5%，n=20）	33 / 961（3.4%）	36（24 / **3** / **4** / 5）	100%	0.951

三個結論。第一，例句是多餘的：拿掉 25 條例句，種子反而多對 2 條（「開 YouTube」在 full 下被 `開啟github.com → open_url` 那條例句帶偏，noex 答 open_application），一致性違反只差 0.4–0.6 個百分點——這跟 EX_DEL 七成存活是同一件事從另一邊看。第二，定義有用，而且用在邊界：連定義都拿掉，種子掉 5 條、一致性違反翻倍（3.9% → 6.0%、2.7% → 5.3%），掉的都是 info / model / set_volume 的邊界句（「台北 top 10 美食」跑去 Google、「音量太大我的耳朵痛」真的把音量調小）。第三，換大一號的模型，錯的還是那幾句：flash 錯的 10 條裡 8 條跟 flash-lite 重疊，都是 prompt 的問題（漏列 download_file / list_windows、info 與 model 的邊界沒寫清），不是模型能力的問題；大模型對例句、定義、全域規則更不依賴（EX_DEL 存活 18 → 22、DEF_DEL 19 → 21、五條全域規則只剩 1 個 dominator），但刪意圖仍是 24 / 24 全殺。flash 對表面噪音免疫、對語意改寫不是：模型批次的 33 個違反裡，禮貌語與填充詞兩條關係合計只錯 1 句，其餘在同義詞與語序——7 個又是「開 YouTube」種子是異類，14 個在 info / model 邊界（「開會中安靜一點」→ 靜音，比種子的期望還合理）。縮減保留 100%、APFD additional 約 0.95，在 3 個受測對象 × 2 個模型 × 3 種寫法下一次都沒變。

這一步還抓到測試工具的第五個 bug：flash 會「思考」，思考的 token 算進輸出上限，JSON 被截成 `{"kind": "`，187 句裡 51 句解析失敗。失敗是隨機的，同一句在原 prompt 下失敗、在突變 prompt 下成功就被算成「殺」——那一輪的突變分數 0.575 是灌水的，修好（關掉思考、放大上限、失敗不進快取）之後是 0.45。錯誤標籤會讓突變分數變好看，這是突變測試自己不會告訴你的事。

十一、成本與效益總表：模型生成器該花在 n 不是溫度，突變測試的九分鐘是縮減唯一有價值的輸入

把 E1–E12 每個方法花什麼、換到什麼放在同一把尺上。時間是實測（單線程）；API 次數從快取的 meta 數出來；費用是付費層的上限估算（gemini-3.5-flash-lite 標準價 $0.30 / 1M 輸入、$2.50 / 1M 輸出，官方價目；以 1 個中文字 ≈ 1 token 粗估，路由 prompt 約 2,000 token；免費層存在，實際可能是 $0）。gemini-3.5-flash 的價格在價目頁上沒找到，不估。

測試從哪裡來。

方法	成本	產出	效益（router v0 第一次 / v5）
手寫 golden tests	五輪人工累積 120 條	120 句	當回歸集；蛻變測試找到的 433 個違反它一個都沒抓到
規則式生成器	0 API、1 秒	928 → 1,373 句	v0：433 違反 / 83 個錯；v5：7；保留原意 91.5%
模型生成 n=5（一批）	205 次 API、約 3 分鐘、≈ $0.07	964 句	v0 T0.7：396 違反 / 150 個錯（規則式的 2 倍）；v5：約 90 / 60；保留原意 96.5%
模型生成 n=20（一批）	193 次 API（跟 n=5 一樣多）、約 5 分鐘、≈ $0.2	3,850 句	v5：623–681 違反 / 167–182 個錯；四批聯集 110 → 273、六批 315
換溫度 / 重跑	每批同上	同上	錯集合 Jaccard 溫度之間 = 重跑之間：多跑一個溫度 = 多跑一次 T=0
真實使用紀錄當種子	0 API	24 種子 → 390 句	4 個現行錯，3 個是缺規則，87 條自寫種子完全沒碰到

留多少、先測哪些。

方法	成本	效益
regex 突變測試	離線：927 個突變體 20 秒；矩陣 2,433 × 927 不到 9 分鐘、13,879 × 1,120 約 12 分鐘	3,355 → 196 條（5.8%）保留 100%（隨機 54%）；APFD 0.985；存活體分析抓到 2 處死碼
不跑突變，按關係 × 種子留一條	免費	保留 56–60% = 隨機
模板突變（Home Assistant）	離線 8 分鐘	縮減 100% vs 隨機 43%

方法	成本	效益
prompt 突變（模型路由）	1,496 次 API、22 分鐘（flash-lite）/ 12 分鐘（flash，4 線程）、≈ $1	縮減 187 → 25 保留 100%（隨機 43%）、APFD 0.95；指出哪些例句 / 定義多餘
跨版本沿用舊子集	0（不重算）	隔一輪保留 84–85%、隔四輪 41–43%：每版重算的 9 分鐘比丟 15% 殺傷力便宜

受測對象上線的代價。

路由器	每句成本	一致性違反（規則式 / 模型批次）	修一個錯要什麼
regex v6	0 API、1.5 ms	0.5% / 7.4%	改 regex、跑 1 秒回歸、0 元
gemini-3.5-flash-lite	1 次 API、約 0.9 秒、≈ $0.0007	3.9% / 2.7%	改 prompt、重跑約 2,500 句驗證（≈ $1.7、10 分鐘）；T=0 仍 1% 翻答
gemini-3.5-flash	1 次 API、約 1 秒、價格未確認	2.5% / 3.4%	同上；錯的句子跟 flash-lite 同一批，換模型不解決 prompt 的洞

三個結論。模型生成器最劃算的參數是 n 不是溫度：同樣 193 次呼叫，n=20 多找 2.5 倍的錯，多跑一個溫度則跟重跑一次沒有分別。突變測試的九分鐘是縮減唯一有價值的輸入：沒有它，縮減等於隨機；有它，5.8% 的測試保留 100% 殺傷力。模型路由贏在自然改寫的穩定度，輸在每句 600 倍的延遲和每句都要付費——對桌面助理，regex 收常見句型、模型接長尾（現在的 → model fallback）是成本上合理的分工。

伍、回饋到產品

一、五輪修正

每一輪都是先把違反歸納成「原因」再修，不針對個別句子；每類留一句進 CI 的 golden tests（最後 80 條）。

輪	來源	原因	修法	效果
1	規則式批次	startswith 型規則對前綴零容忍；句尾語助詞黏進目標；否定句、問句照做；URL 規則吃中文	正規化層（剝填充詞 / 客氣話 / 語助詞）、否定與問句守門、網域只認 ASCII	規則式 433 → 52；R4 41% → 0%、R5 40% → 0%
2	模型批次的 X → model	真人會講的句型沒收（意願句、受詞在前、平台片語）；關鍵字規則太貪（「播放一下周杰倫」變媒體鍵）	加句型；媒體鍵 / 報時改整句比對	模型 T0.7 396 → 194
3	模型批次剩下的錯	同一件事一堆講法（鎖定 / 切換 / 下一首）；問法的外圍詞；搜尋動詞 + 問資訊	每類一條 regex；先剝問法外圍詞；搜尋 + 資訊內容走純問答	T0.7 194 → 111
4	存活突變體、E2 的 R2 違反、R3 長尾	死碼（lens 的「找來源」被搜尋的「找」先接）；「…好嗎」把任務變成問答；「記事本幫我打開」沒規則收	觸發順序調整；問答判斷先正規化；受詞在前的句型翻回動詞在前（有分隔才直接翻，沒分隔只當最後 fallback）	規則式 81 → 7；模型 約 130 → 約 90
5	n=20 六批的 315 個錯、真實使用的 4 個錯	填充詞後面的省略號 / 波浪號（「那個…」「嗯～」「Jarvis 幫我！」）沒收；禮貌語黏進目標（「拜託你了嗎」「謝謝你」）；語序句的動詞尾（「打開來」「啟動起來」）讓目標只剩「來」；整句包含指令片語的問句 / 陳述句照觸發（「音量調大是要按哪個按鈕」）；「搜尋 X 並播放」「下載 X 於桌面」「開啟螢幕」「截取」沒規則	填充詞與尾語詞表擴充、受詞尾綴（程式 / 軟體 / 捷徑）剝掉、SOV 動詞加「打開來 / 啟動起來 / 點開 / 叫出來」、問句守門加「怎麼 / 哪個按鈕 / 不小心 / 上次」、否定詞加「取消」；五條新規則；27 條黃金案例	n=20 六批 4,069 → 2,919 違反（修掉 1,150、0 回歸）；真實使用 54 → 3；模型 n=5 約 90 → 77

第四輪的修法是看 T0.7 那批的清單歸納的：T0.7 降 40%、其他批次降 30%，從一批歸納的修正有七成能推到另一批。對使用者的意思是：「記事本幫我打開」「把截圖整理到資料夾好嗎」這類句子從「花 token 交給模型」或「變成問答不做事」變成本機直接做。

二、測試工具自己也要測

研究過程中測試工具本身被自己的方法抓到四次錯，每次都會改變結論：

1. 測試基座的標籤比對：`computer:key:nexttrack` 被拆成不同結構，「下一首」的 77% 脆弱度有一半是假象。
2. 種子含其他規則的觸發詞：「搜尋台北天氣」改寫後被天氣規則接走，那不是路由的錯。
3. 模型語意漂移：「播晴天」被改成「搜尋晴天」，違反是測試的錯，E1 量化為 3.5%。
4. 分析腳本的去重順序：造成「T0 殺最多、T1 最少」的假結論，差點進報告。
5. 模型輸出截斷：flash 的思考 token 把 JSON 截成半句，解析失敗被當成標籤，突變分數從 0.45 灌水到 0.575；修兩次才好，第一次改了寫入快取、沒改讀快取。

另外，存活突變體的人工分類若沒有「每個判斷附一句可執行的 killer」，第一輪 33% 的誤判也會直接進報告。這些經驗的共同結論：測試生成、測試基座、分析腳本都是程式，都會錯，都要有自己的檢查。

陸、研究限制與效度威脅

- **種子選擇**：41 條原始種子是我挑的，偏向我知道 router 會做的事；46 條 killer 種子是對著存活突變體寫的，偏向 regex 的詞表。緩解：第三批種子從真實使用紀錄來（RQ8），找到 4 個缺規則的錯；但只有一位使用者的紀錄，而且英文指令沒當種子。
- **單一受測對象**：緩解：RQ9 把同一套跑在 Home Assistant 的 zh-TW 模板上，縮減 / 排序結論重現。RQ10 再加了模型路由，E12 換過一個模型（flash）和兩種 prompt 寫法，結論不變；但兩個模型同家族，非 Gemini 的模型沒試；HA 沒跑模型生成器，種子是模板展開的。
- **生成句的有效性**：E1（n=5 與 n=20 各 400 句）目前只有一位標記者，尚未算 Cohen's κ；標記者同時是開發者。兩次標記的比例（96.5% / 94.8%）和掉分的關係（R3）一致，是自洽不是信度。
- **等價突變體**：只抽 60 個人工估（18%），推回全體有誤差。
- **批次規模**：溫度在 n=5 與 n=20 都看不出影響，但只試了一個模型（gemini-3.5-flash-lite）與一種 prompt；n=20 的改寫句沒有人工標記，有效率 96.5% 是 n=5 的數字，批次放大後漂移比例可能較高；n=20 批次也沒有進突變矩陣。
- **我既是開發者也是實驗者**：修 router 時知道測試長什麼樣。緩解：只針對分類後的原因修，不針對個別句子；golden tests 與生成測試分開；第四輪用「看一批、驗其他批」量化推廣性。

柒、結論與未來工作

一、結論

1. **該測什麼**：蛻變關係讓沒有 oracle 的自然語言路由也能自動生成測試；第一次就在 928 句裡找到 433 個手寫測試沒抓到的違反。模型生成器找到的錯是模板的兩倍，改寫有效率 96.5%，模板生成器則是免費、確定、一秒跑完的對照組。
2. **測試多可靠**：溫度在 n=5 和 n=20 兩個規模下對找錯數、錯集合、殺傷力都沒有可見影響，溫度之間的差異與 T=0 重跑的雜訊相同；真正有影響的生成參數是批次大小（n=5 → 20，去重錯 110 → 273，多出來的大多是真錯）。用模型生成測試的比較必須附重跑底線。
3. **留多少**：以突變體為需求，3,355 條縮到 196 條（5.8%）仍保留 100% 殺傷力，greedy / HGS / irreplaceable 三種策略幾乎一樣；不跑突變測試的便宜準則跟隨機沒有差別。
4. **先測哪些**：additional 排序 APFD 0.985，跑前 10% 就找到全部的錯；total 排序輸給隨機。
5. **跨版本還有用**，但會過期：在 v4 縮減的子集套到 v5 保留 84–85% 殺傷力（隨機 50%），掉的那 15% 全是新版才出現的規則（v5 → v6 只加詞表，保留 95%）；隔四輪（v0 → v5）只剩 41–43%，additional 排序更比隨機還差。縮減子集可以跨版本用，但每加一條規則要補守它的種子，排序更要每版重算。
6. **突變分數要看最小分數**：485 個可殺突變體裡只有 238 個是獨立的錯；BOOL / OPT_DEL / NUM / LOOK_DEL 九成以上被詞表突變體包含，隨機子集的真實找錯能力只有一般分數的一半。分數也要看測試集有沒有跟上規則：v6 用舊矩陣算掉到 0.42，加 n=20 批次後回到 0.50；測試多四倍後 dominator 升到 55%、縮減到 1.8% 仍保留 100%、隨機子集最小分數只剩 18%。
7. **突變測試量不到缺的規則**：真實使用紀錄找到的 4 個現行錯裡 3 個是 router 沒有那條規則，突變體只能改現有規則；自寫種子覆蓋了真實使用殺傷的 98%，但使用次數第二高的指令完全沒測到，27% 的指令是英文。
8. **結論不只對這一個 router 成立**：同一套跑在 Home Assistant 的 520 條 zh-TW 模板上，縮減保留 100% vs 隨機 43%、additional 最好、關係優先最差、便宜準則等於隨機，四個結論全部重現；但哪種突變體多餘跟實作有關（整句匹配下可選群組是獨立的錯），而且兩個受測對象錯的方向相反：找關鍵字的誤觸發，整句匹配的該觸發沒觸發。
9. **模型路由是另一種取捨，不是替代品**：零調校的 Gemini 路由在自然改寫上比 regex v6 穩（一致性違反 2.7% 對 7.4%）、在模板句上輸（3.9% 對 0.5%），會出 regex 不會出的錯（種子本身是異類）、T=0 仍有 1% 翻答，每句要一次 API。prompt 突變顯示刪意圖一定被殺、刪例句 / 定義七成等價；換寫法驗證了這一點（拿掉例句不掉分、拿掉定義一致性違反翻倍），換大一號的模型錯的仍是同一批句子、例句與定義更多餘。縮減與排序的結論在 3 個受測對象 × 2 個模型 × 3 種 prompt 寫法上一樣。
10. **回饋**：五輪修正把規則式批次的違反從 706 降到 7、模型批次從約 415 降到約 77，無反彈；第五輪把 n=20 找到的錯修掉 1,150 個、零回歸；生成的測試批次同時成為回歸集，抓到修正過程中新壞的句子。

11. **測試工具自己也要測**：測試基座、種子、生成器、分析腳本、模型輸出截斷各被抓到一次錯，每次都會改變結論；錯誤標籤會把突變分數灌水（0.575 → 0.45）。
12. **成本效益**：模型生成器該花在 n 不是溫度（同樣 193 次呼叫，n=20 多找 2.5 倍的錯）；突變測試的九分鐘是縮減唯一有價值的輸入；模型路由每句 0.9 秒、要付費，regex 1.5 ms、免費——regex 收常見句型、模型接長尾是合理的分工。

二、未來工作

- 找第二位標記者完成 E1，算 Cohen's κ。
- 對 n=20 批次補抽 400 句人工標記，量批次放大後的漂移比例；把 n=20 六批進突變矩陣，看 315 個錯多殺幾個突變體。
- 把 RQ8 找到的 4 個缺規則的錯修回 router（第五輪），英文指令也當種子；收更多使用者的紀錄。
- 在 Home Assistant 上跑模型生成器，把「客廳燈幫我打開 → 問狀態」回報給上游。
- E11 換模型（非 flash-lite）與換 prompt 寫法再跑一次，看「例句七成等價」是不是通則；把 prompt 突變矩陣的測試從 187 句加到全批。

參考文獻

1. T. Y. Chen, S. C. Cheung, S. M. Yiu. Metamorphic testing: a new approach for generating next test cases. Technical Report HKUST-CS98-01, Hong Kong University of Science and Technology, 1998.
2. R. A. DeMillo, R. J. Lipton, F. G. Sayward. Hints on test data selection: Help for the practicing programmer. IEEE Computer, 11(4): 34–41, 1978. doi:10.1109/C-M.1978.218136
3. Y. Jia, M. Harman. An analysis and survey of the development of mutation testing. IEEE Transactions on Software Engineering, 37(5): 649–678, 2011. doi:10.1109/TSE.2010.62
4. M. J. Harrold, R. Gupta, M. L. Soffa. A methodology for controlling the size of a test suite. ACM Transactions on Software Engineering and Methodology, 2(3): 270–285, 1993. doi:10.1145/152388.152391
5. G. Rothermel, R. H. Untch, C. Chu, M. J. Harrold. Prioritizing test cases for regression testing. IEEE Transactions on Software Engineering, 27(10): 929–948, 2001. doi:10.1109/32.962562
6. C.-T. Lin, K.-W. Tang, G. M. Kapfhammer. Test suite reduction methods that decrease regression testing costs by identifying irreplaceable tests. Information and Software Technology, 56(10): 1322–1344, 2014. doi:10.1016/j.infsof.2014.04.013
7. C.-T. Lin, K.-W. Tang, J.-S. Wang, G. M. Kapfhammer. Reducing the cost of regression testing by identifying irreplaceable test cases. Proc. 6th International Conference on Genetic and Evolutionary Computing (ICGEC), pp. 257–260, 2012. doi:10.1109/ICGEC.2012.124

8. M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh. Beyond Accuracy: Behavioral Testing of NLP Models with CheckList. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL), pp. 4902–4912, 2020. doi:10.18653/v1/2020.acl-main.442
9. J. Wang, Y. Huang, C. Chen, Z. Liu, S. Wang, Q. Wang. Software Testing With Large Language Models: Survey, Landscape, and Vision. IEEE Transactions on Software Engineering, 50(4): 911–936, 2024. doi:10.1109/TSE.2024.3368208
10. 本研究程式碼與數據：github.com/Venshen885361/jarvis-desktop，`research/` 目錄。

※ 第 2–9 條的卷期頁碼與 DOI 已依 Crossref / ACL Anthology 核對（2026-10-13）；第 1 條為技術報告，無卷期。格式交稿前依學校規定調整。